顧客市場分析X機器學習

Customer Analytics with Machine Learning

這次分析目的

❖主要目的：

1. 利用Python機器學習針對不同特徵進行分類，再利用分類好的群組對加上特定特徵預測消費者購買的品牌。
2. 不同區塊對於價格的反應程度，藉此擬訂行銷策略，提高銷售額以及穩定市場佔有率。

❖此分析有效商家為:

1. **擁有該資料的賣場**：可利用此分析進行促銷、商品陳列位置更改或是對該客群的顧客推薦類似商品以提升營業額。
2. **想要進入該市場的商家**：可藉此資料了解到不同客群所喜歡的品牌樣式，提升商家的品牌定位精準度。

分析項目

1. 依照各區塊族群來進行品牌偏好、銷售額以及購買機率價格彈性分析。

分析資料-1

2000筆不同ID的:

- 性別
- 婚姻
- 年齡
- 教育程度
- 收入
- 職業
- 居住的城市大小

segmentation data.csv(8 features)

ID	Sex	Marital stat	Age	Education	Income	Occupation	Settlement size
100000001	0	0	67	2	124670	1	2
100000002	1	1	22	1	150773	1	2
100000003	0	0	49	1	89210	0	0
100000004	0	0	45	1	171565	1	1
100000005	0	0	53	1	149031	1	1
100000006	0	0	35	1	144848	0	0
100000007	0	0	53	1	156495	1	1
100000008	0	0	35	1	193621	2	1
100000009	0	1	61	2	151591	0	0
100000010	0	1	28	1	174646	2	0
100000011	1	1	25	1	108469	1	0
100000012	1	1	24	1	127596	1	0
100000013	1	1	22	1	108687	1	2
100000014	0	0	60	2	89374	0	0
100000015	1	1	28	1	102899	1	1
100000016	1	1	32	1	88428	0	0
100000017	0	0	53	1	125550	1	0
100000018	0	0	25	0	157434	1	2
100000019	1	1	44	2	261952	2	2
100000020	0	0	31	0	144657	1	1
100000021	0	0	48	1	118777	1	1
100000022	0	0	44	1	147511	1	1
100000023	0	0	48	1	89804	0	0
100000024	0	0	44	1	134918	1	2

分析資料-2

共5萬多筆不同ID的:

- 進入該店的時間
- 有無購買
- 品牌
- 數量
- 上次購買的品牌
- 上次購買品牌的數量
- 品牌價格1~5
- 品牌促銷1~5
- Segment Data的:
    - 性別
    - 婚姻
    - 年齡
    - 教育程度
    - 收入
    - 職業
    - 居住的城市大小

purchase data.csv(24 features)

ID	Day	Incidence	Brand	Quantity	Last_Inc_Bra	Last_Inc_Qu	Price_1	Price_2	Price_3	Price_4	Price_5
200000001	1	0	0	0	0	0	1.59	1.87	2.01	2.09	2.66
200000001	11	0	0	0	0	0	1.51	1.89	1.99	2.09	2.66
200000001	12	0	0	0	0	0	1.51	1.89	1.99	2.09	2.66
200000001	16	0	0	0	0	0	1.52	1.89	1.98	2.09	2.66
200000001	18	0	0	0	0	0	1.52	1.89	1.99	2.09	2.66
200000001	23	0	0	0	0	0	1.5	1.9	1.99	2.09	2.66
200000001	28	1	2	2	0	0	1.5	1.9	1.99	2.09	2.67
200000001	37	0	0	0	2	1	1.5	1.9	1.99	2.09	2.67
200000001	41	0	0	0	0	0	1.35	1.58	1.97	2.09	2.67
200000001	43	0	0	0	0	0	1.35	1.58	1.97	2.09	2.67
200000001	51	0	0	0	0	0	1.35	1.87	1.93	2.09	2.59
200000001	58	1	5	1	0	0	1.39	1.9	1.91	2.12	2.62
200000001	59	0	0	0	5	1	1.39	1.9	1.91	2.12	2.62
200000001	77	0	0	0	0	0	1.36	1.85	1.95	2.12	2.5
200000001	78	0	0	0	0	0	1.47	1.85	1.95	2.12	2.5
200000001	83	0	0	0	0	0	1.47	1.9	1.99	2.12	2.49
200000001	90	0	0	0	0	0	1.39	1.58	1.99	2.12	2.55
200000001	92	0	0	0	0	0	1.39	1.46	1.99	2.12	2.4
200000001	98	0	0	0	0	0	1.47	1.9	1.95	2.12	2.67
200000001	110	1	1	2	0	0	1.47	1.9	1.99	1.97	2.67
200000001	111	0	0	0	1	1	1.47	1.9	1.99	1.97	2.67
200000001	118	0	0	0	0	0	1.43	1.31	1.99	2.16	2.67

Promotion_	Promotion_	Promotion_	Promotion_	Promotion_	Sex	Marital stat	Age	Education	Income	Occupation	Settlement size
0	1	0	0	0	0	0	47	1	110866	1	0
0	0	0	0	0	0	0	47	1	110866	1	0
0	0	0	0	0	0	0	47	1	110866	1	0
0	0	0	0	0	0	0	47	1	110866	1	0
0	0	0	0	0	0	0	47	1	110866	1	0
0	0	0	0	0	0	0	47	1	110866	1	0
0	0	0	0	0	0	0	47	1	110866	1	0
0	0	0	0	0	0	0	47	1	110866	1	0
1	1	1	0	0	0	0	47	1	110866	1	0
1	1	1	0	0	0	0	47	1	110866	1	0
1	1	1	0	0	0	0	47	1	110866	1	0
1	0	0	0	1	0	0	47	1	110866	1	0
1	0	0	0	0	0	0	47	1	110866	1	0
0	1	0	0	0	0	0	47	1	110866	1	0
0	0	0	0	1	0	0	47	1	110866	1	0
0	0	0	0	1	0	0	47	1	110866	1	0
0	1	0	0	0	0	0	47	1	110866	1	0
0	0	0	0	0	0	0	47	1	110866	1	0
0	0	0	0	0	0	0	47	1	110866	1	0
0	0	0	1	0	0	0	47	1	110866	1	0
1	1	0	0	0	0	0	47	1	110866	1	0
0	1	0	0	0	0	0	47	1	110866	1	0

分析工具

- 預處理(Preprocessing): StandardScaler
- 分群(Clustering): linkage、dendrogram(SciPy)、KMeans(scikit-learn)
- 分解(Decomposition): Principal Component Analysis(PCA)
  - 利用PCA轉換維度，將其影響程度略低的component去除。
- 曲線模型(linear_model): LogisticRegression
  - 羅吉斯回歸線為分類演算法，設計來預測分類目標對象(target labels)。
- 製圖: matplotlib、seaborn
- 機器學習演算法: PySpark、Sickit-learn

STP Marketing Model

利用以下方式找出市場利基

- 市場區隔(**S**egmentation): 依照相似的特徵區分為不同族群做區隔
- 市場目標(**T**argeting): 從市場區隔評估潛在利益，決定傳住的區塊
- 市場定位(**P**ositioning): 什麼形式的商品可以吸引到該族群

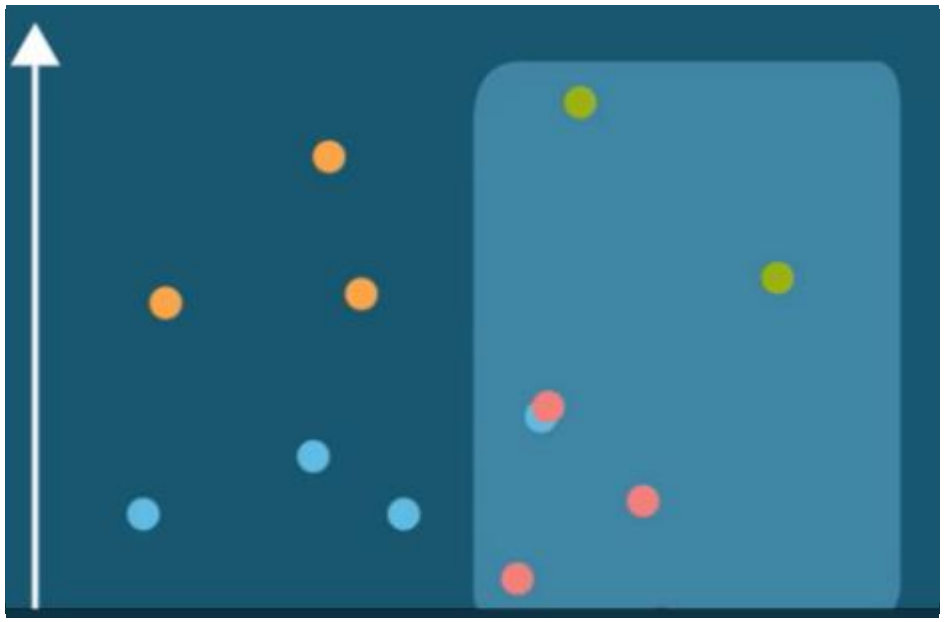

Hierarchical Clustering

在這個地方立永平衡好的資料針對不同特徵所產生的距離差，利用Ward’s linkage method計算出在平衡後各點的距離，進而分類。

- 下一張圖可以看到，下圖紅框的參數得以分出4~6個區塊
- Hierarchical Clustering 比flat clustering (比方說K-means)慢，但是可以先用Hierarchical Clustering做分類(知道有幾個clusters)，再用 flat clustering做segementation

```
from sklearn.preprocessing import StandardScaler
from scipy.cluster.hierarchy import dendrogram, linkage

scaler = StandardScaler()
segmentation_std = scaler.fit_transform(df_segmentation)
hier_clust = linkage(segmentation_std, method = 'ward')

plt.figure(figsize = (12,9))
plt.title('Hierarchical Clustering Dendrogram')
plt.xlabel('Observations')
plt.ylabel('Distance')
dendrogram(hier_clust,
           truncate_mode = 'level',
           p = 5,
           show_leaf_counts = False,
           no_labels = True)
plt.show()
```

Standardization&Hierarchical Clustering

method = 'complete'

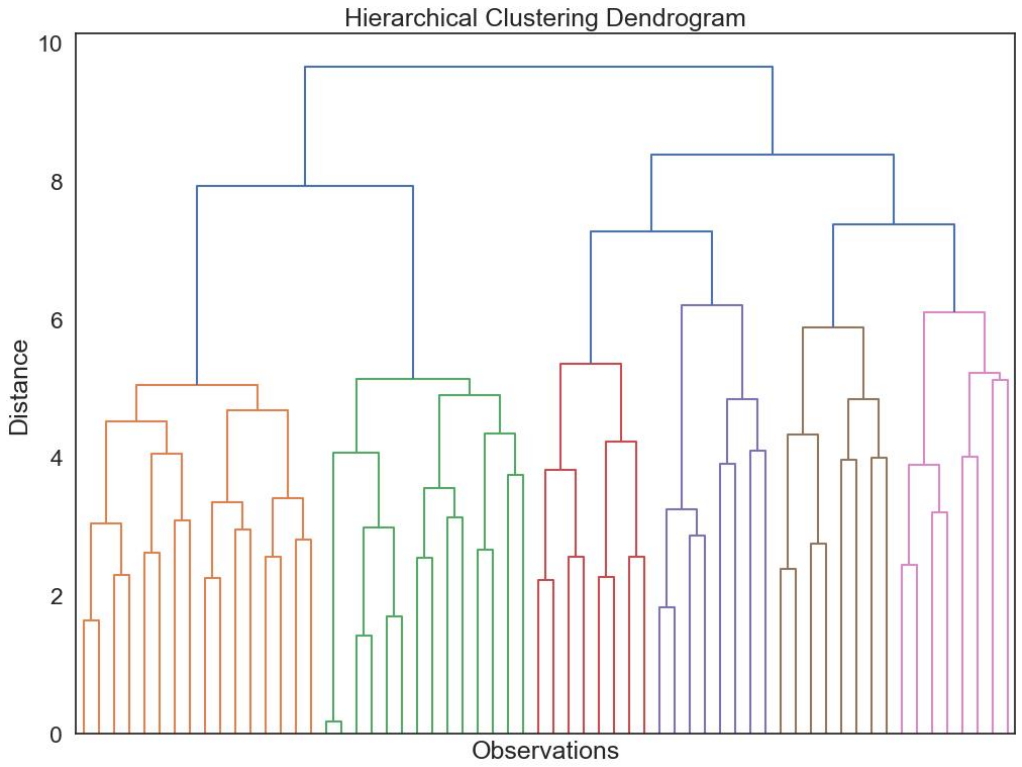

method = 'ward'

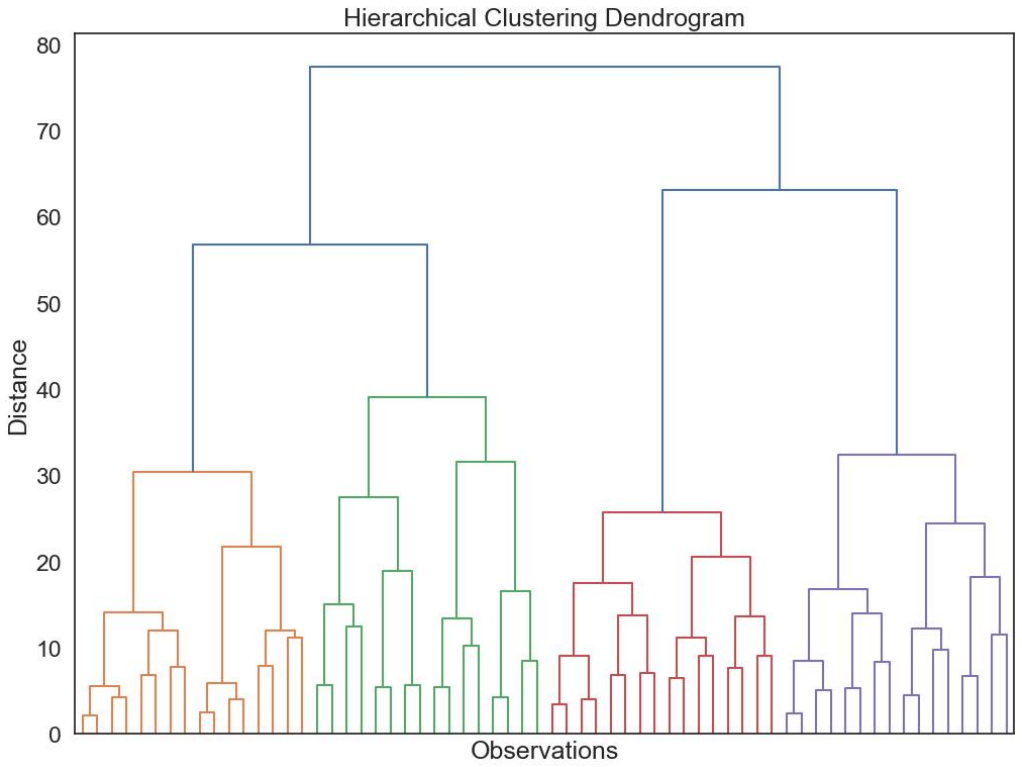

K-means Clustering

利用上面的演算法已先初步得知群體個數，再來利用K-means做最後的確認。

```
wcss = []
for i in range(1,11):
    kmeans = KMeans(n_clusters = i, init = 'k-means++', random_state = 42)
    kmeans.fit(segmentation_std)
    wcss.append(kmeans.inertia_)

plt.figure(figsize = (10,8))
plt.plot(range(1, 11), wcss, marker = 'o', linestyle = '--')
plt.xlabel('Number of Clusters')
plt.ylabel('WCSS')
plt.title('K-means Clustering')
plt.show()
```

K-means Clustering

利用個點與cluster的平方距離總和(sum of the squared distances)，在不同總和間找到一個凹折，有一個普遍的方法叫做elbow method，由右圖可以微微的看到紅色圈起來的地方有趨緩的現象，因此可以選擇cluster=5。

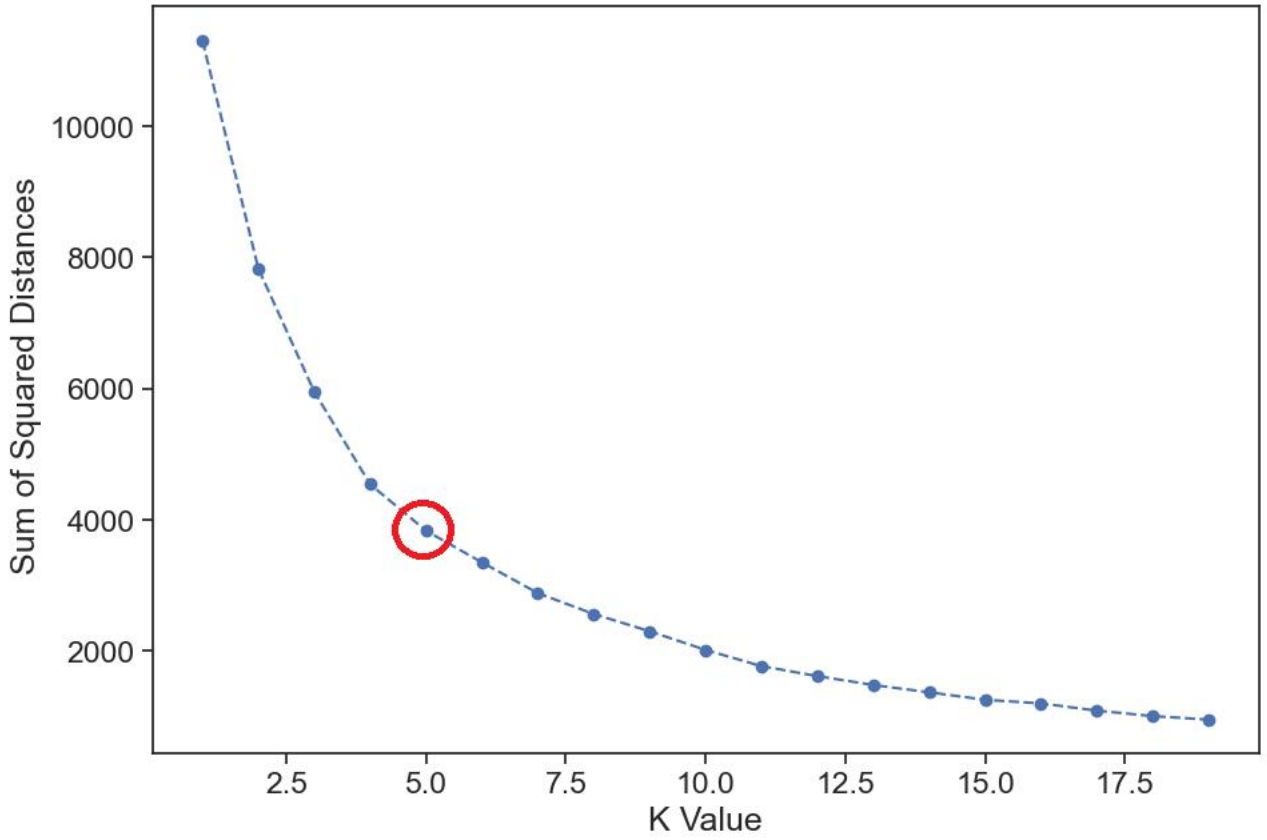

K-means Clustering

最後的表做出來有三個clusters幾乎混在一起，只有綠色的群體有稍微分開，接下來用主成分分析(pca)修正，可以讓分類比較明顯。

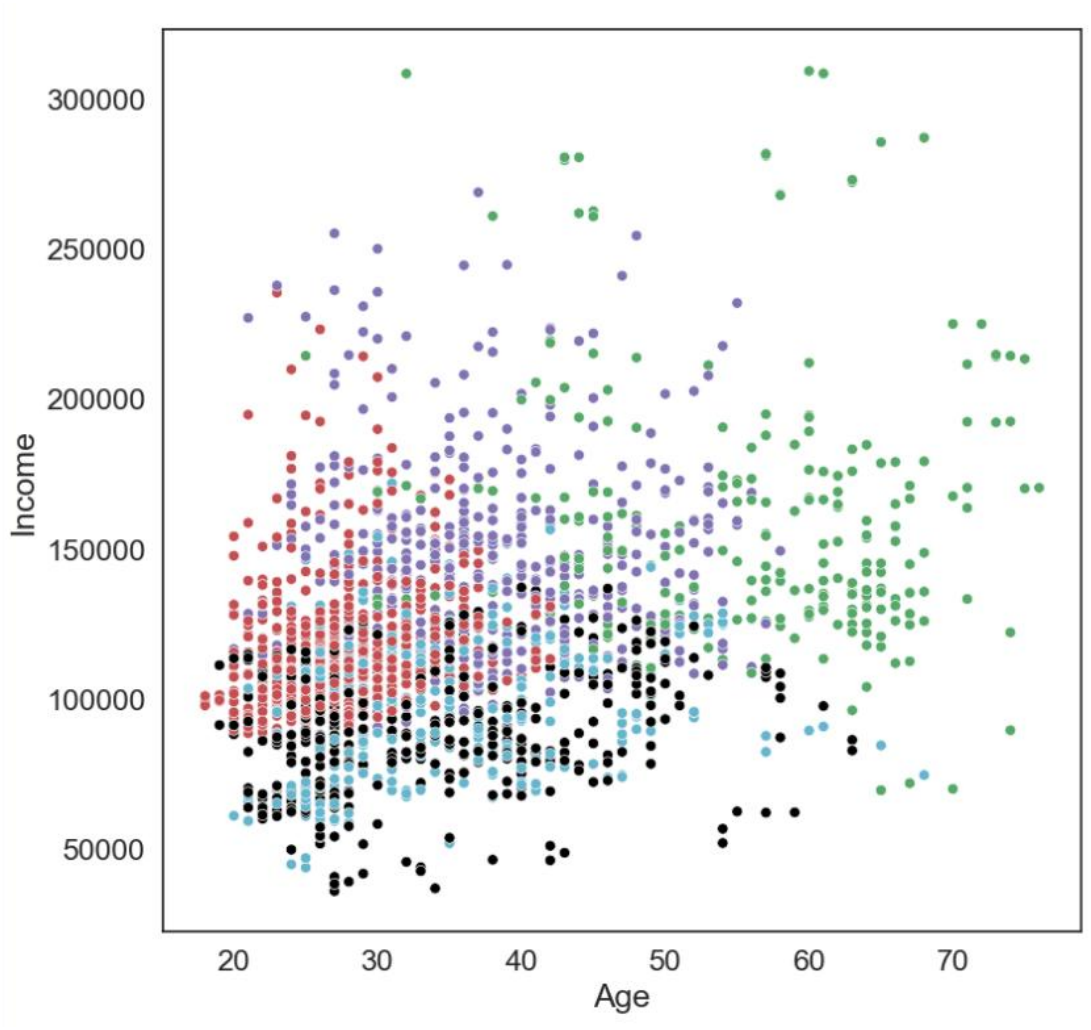

Principal Component Analysis(PCA)

- 主成分分析(PCA)以原資料產生出該特徵數量的成分(Component)數，在各個成分數裡，可以選擇變異數(variance)最多的幾個成分，可以做到最佳分類。
- 根據經驗法則，explained_variance_ratio_，80%的資料成分數據分析最佳，右圖可以看到利用解釋方差紅色圈起來的地方剛好在0.8左右。

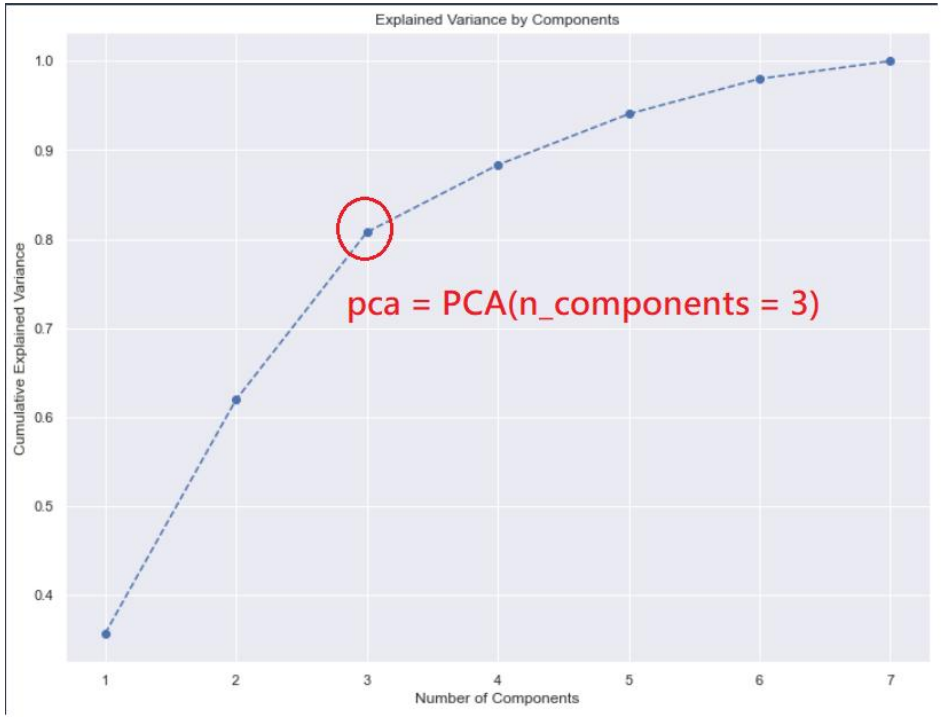


```
#找到PCA commponents
pca = PCA()
pca.fit(segmentation_std)
print(pca.explained_variance_ratio_)

#圖表顯示，可看出最佳commponents數
plt.figure(figsize = (12,9))
plt.plot(range(1,8), pca.explained_variance_ratio_.cumsum(), marker = 'o', linestyle = '--
plt.title('Explained Variance by Components')
plt.xlabel('Number of Components')
plt.ylabel('Cumulative Explained Variance')
```

PCA Results


```python
#選擇n_components=3
pca = PCA(n_components = 7)
pca.fit(segmentation_std)

#下面了解到components跟原始數據的關係，把它做成heatmap看得更清楚
df_pca_comp = pd.DataFrame(data = pca.components_,
                           columns = df_segmentation.columns.values,
                           index = [f'component {x}' for x in np.arange(1,8)])

plt.figure(figsize=(12,10),dpi=80)
sns.heatmap(df_pca_comp,
            vmin = -1,
            vmax = 1,
            cmap = 'RdBu',
            annot = True)
plt.yticks(np.arange(1,8),
           [f'component {x}' for x in np.arange(1,8)],
           rotation = 45,
           fontsize = 9);
```

依照上一頁的解釋，我們選擇最上面的三個components

PCA Results

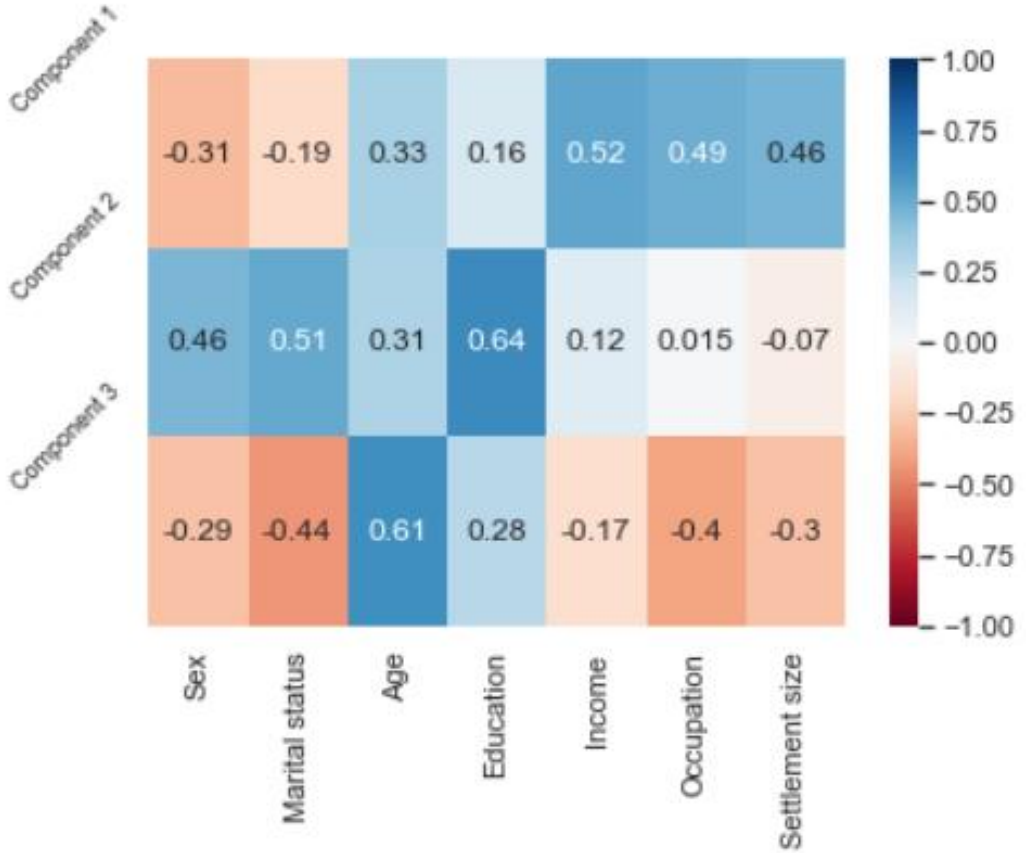

右圖可以看到:

- 越接近0，表示相關越低，這邊看到相關係數在0.5以上較為重要。
- component1 與Income, ccupation, Settlement size相關性比較大，這表示它們相互影響力大，所以可推測它們應該是專注在事業上多一點，
- component2 跟component1的相關係數相反，所以推測比較專注於學術以及生活方面

K-means clustering with PCA Results

右邊上圖scatterplot可以看到，利用PCA降維後的分群效果比較好。

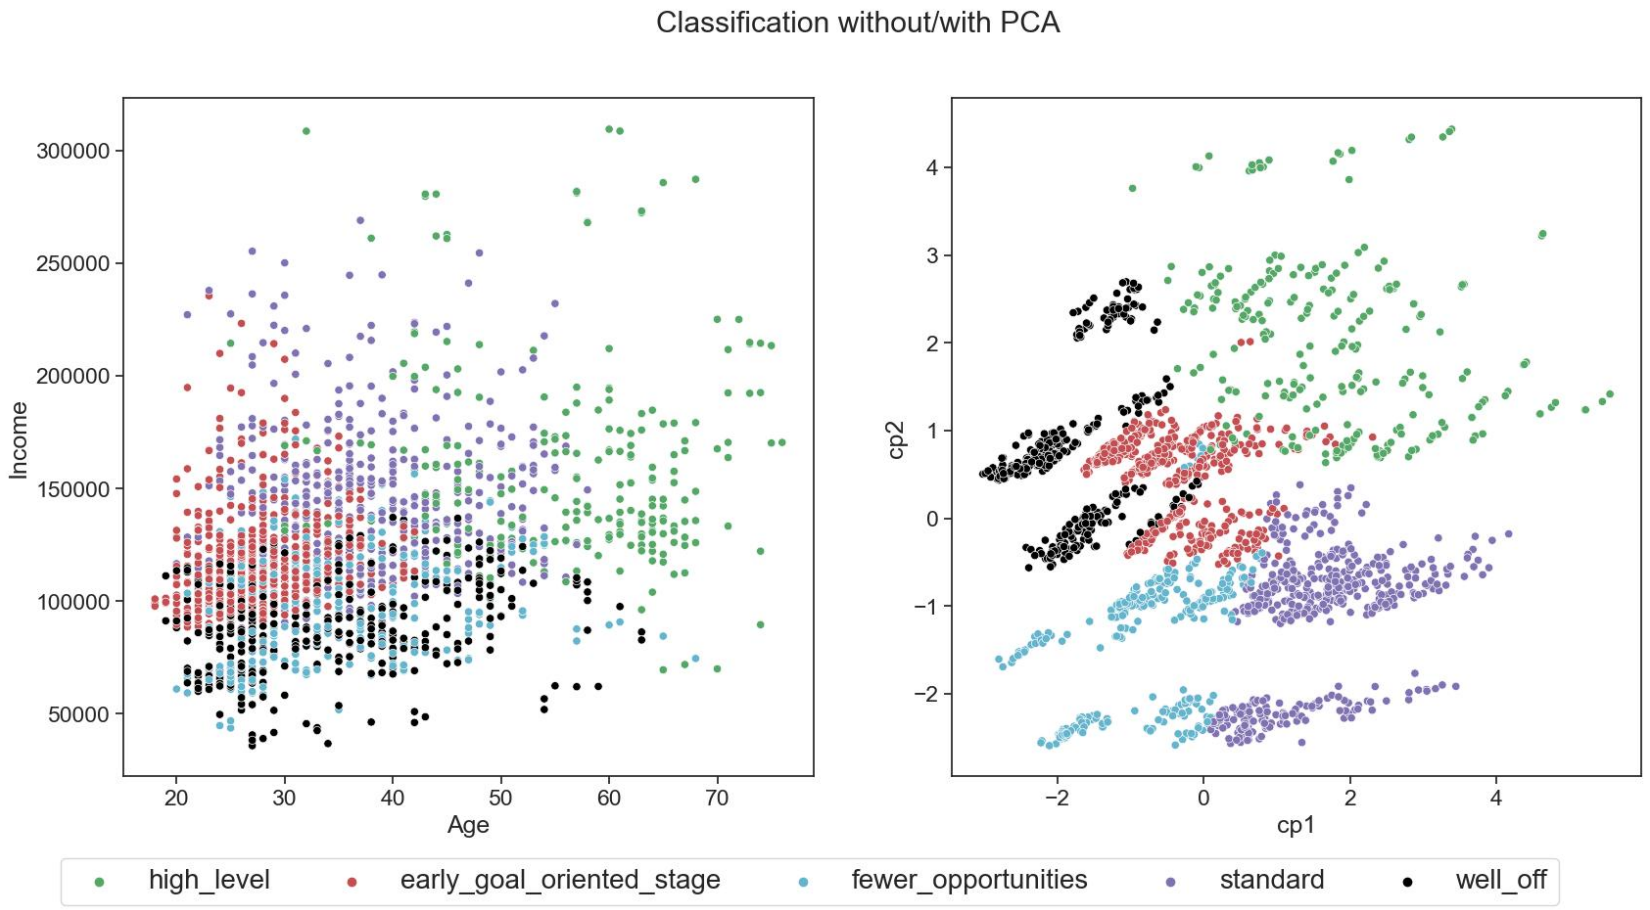

K-means clustering with PCA Results

利用PCA降維，由上圖可以看到分層效果，最終達到針對不同客戶也可以分類的結果，下表可以看到不同客群所呈現的結構狀態。

Segment K-means	Sex	Marital status	Age	Education	Income	Occupation	Settlement size
high_level	0.478088	0.677291	55.764940	2.135458	160996.087649	1.175299	1.147410
fewer_opportunities	0.096386	0.000000	34.506024	0.560241	97094.189759	0.346386	0.117470
well_off	0.879487	0.730769	33.787179	1.179487	88644.882051	0.053846	0.000000
early_goal_oriented_stage	0.779439	0.938318	27.915888	1.003738	119174.517757	1.039252	0.768224
standard	0.004065	0.073171	37.099593	0.725610	144174.142276	1.288618	1.504065

Pickle

利用pickle儲存我們做好的模型，將在接下來的Purchase Data使用

```
pickle.dump(scaler, open('scaler.pickle', 'wb'))
pickle.dump(pca, open('pca.pickle', 'wb'))
pickle.dump(kmeans_pca, open('kmeans_pca.pickle', 'wb'))
```

Purchase Data(分析資料-2)

開始分析各別ID的不同消費行為，共500筆不同ID，

```
df_purchase = pd.read_csv('purchase data.csv')
df_purchase
```

	ID	Day	Incidence	Brand	Quantity	Last_Inc_Brand	Last_Inc_Quantity	Price_1	Price_2	Price_3	...	Promotion_3	Promotion_4	Promotion_5	Sex	Marital status	Age	Education	Income
0	200000001	1	0	0	0	0	0	1.59	1.87	2.01	...	0	0	0	0	0	47	1	110866
1	200000001	11	0	0	0	0	0	1.51	1.89	1.99	...	0	0	0	0	0	47	1	110866
2	200000001	12	0	0	0	0	0	1.51	1.89	1.99	...	0	0	0	0	0	47	1	110866
3	200000001	16	0	0	0	0	0	1.52	1.89	1.98	...	0	0	0	0	0	47	1	110866
4	200000001	18	0	0	0	0	0	1.52	1.89	1.99	...	0	0	0	0	0	47	1	110866
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
58688	200000500	703	0	0	0	2	1	1.41	1.85	2.01	...	1	0	0	0	0	42	1	120946
58689	200000500	710	0	0	0	0	0	1.36	1.84	2.09	...	0	0	0	0	0	42	1	120946
58690	200000500	717	0	0	0	0	0	1.50	1.80	2.14	...	0	0	0	0	0	42	1	120946
58691	200000500	722	1	2	3	0	0	1.51	1.82	2.09	...	0	0	0	0	0	42	1	120946
58692	200000500	726	0	0	0	2	1	1.51	1.82	2.09	...	0	0	0	0	0	42	1	120946

Purchase Data

事前準備資料，先用pickle將模型載卸下來，再將該資料的特徵進行處理

```
features = df_purchase[['Sex', 'Marital status', 'Age', 'Education',
                        'Income', 'Occupation', 'Settlement size']]
df_purchase_segm_std = scaler.transform(features)
df_purchase_segm_pca = pca.transform(df_purchase_segm_std)
purchase_segm_kmeans_pca = kmeans_pca.predict(df_purchase_segm_pca)
df_purchase_predictors = df_purchase.copy()
df_purchase_predictors['Segment'] = purchase_segm_kmeans_pca
df_purchase_predictors
```

	ID	Day	Incidence	Brand	Quantity	Last_Inc_Brand	Last_Inc_Quantity	Price_1	Price_2	Price_3	...	Promotion_4	Promotion_5	Sex	Marital status	Age	Education	Income	Occupation	Settlement size	Segment
0	200000001	1	0	0	0	0	0	1.59	1.87	2.01	...	0	0	0	0	47	1	110866	1	0	2
1	200000001	11	0	0	0	0	0	1.51	1.89	1.99	...	0	0	0	0	47	1	110866	1	0	2
2	200000001	12	0	0	0	0	0	1.51	1.89	1.99	...	0	0	0	0	47	1	110866	1	0	2
3	200000001	16	0	0	0	0	0	1.52	1.89	1.98	...	0	0	0	0	47	1	110866	1	0	2
4	200000001	18	0	0	0	0	0	1.52	1.89	1.99	...	0	0	0	0	47	1	110866	1	0	2
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...

Exploratory Data Analysis

Segments Portions

- 下面圓餅圖可以看到Fewer opportunities的區塊的占比較大，占了約略1/4的總人數，而其他只有約略差距3個百分比左右。

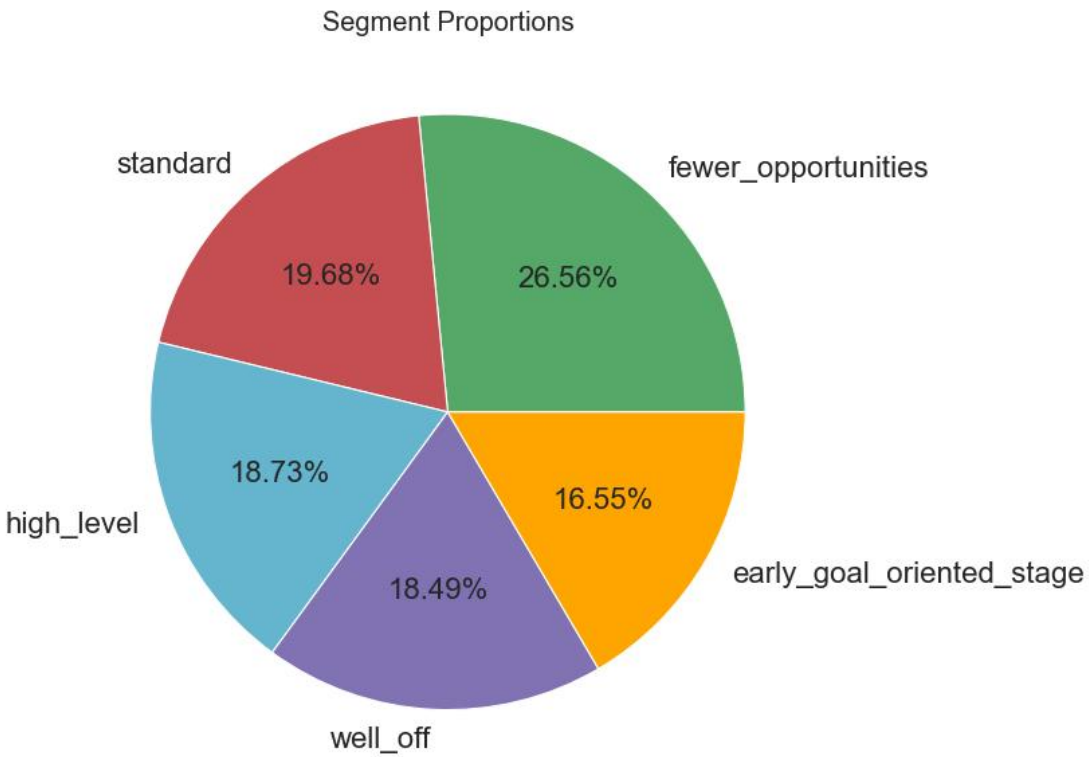


```
'''了解各區塊的分佈比例'''
df_group_protion = df_purchase_segm_kmeans_pca['Segments'].value_counts()/len(df_purchase_segm_kmeans_pca)
labels = df_group_protion.rename(({0:'high_level',
                                   1:'fewer_opportunities',
                                   2:'well_off',
                                   3:'early_goal_oriented_stage',
                                   4:'standard'})).index

plt.figure(figsize = (16,9), dpi=80)
plt.pie(x=df_group_protion,
       labels = labels,
       autopct='%1.2f%%',
       colors = ['g', 'r', 'c', 'm', 'orange'],
       textprops={'fontsize':20});
plt.title('Segment Proportions');
```

Exploratory Data Analysis

Incidence rate

- 用新的Purchase Data裡面的資料計算Incidence rate，即是各個ID每次到該賣場有購買巧克力的機率，這邊可以看到在fewer-opportunity以及well_off的族群，購買率集中在0~30之間，購買機率不大，該產品對於此Segment的消費者來說並非為必需品，結合上圖圓餅圖可以了解到fewer-opportunity的族群雖然佔總資料的1/4，但相較於其他三個族群來說波動差距比較大且購買率低，不建議作為聚焦對象。

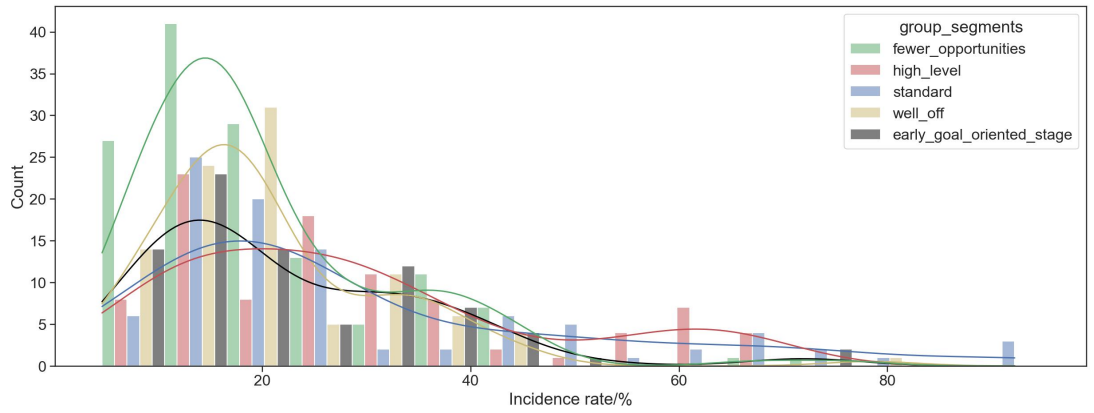

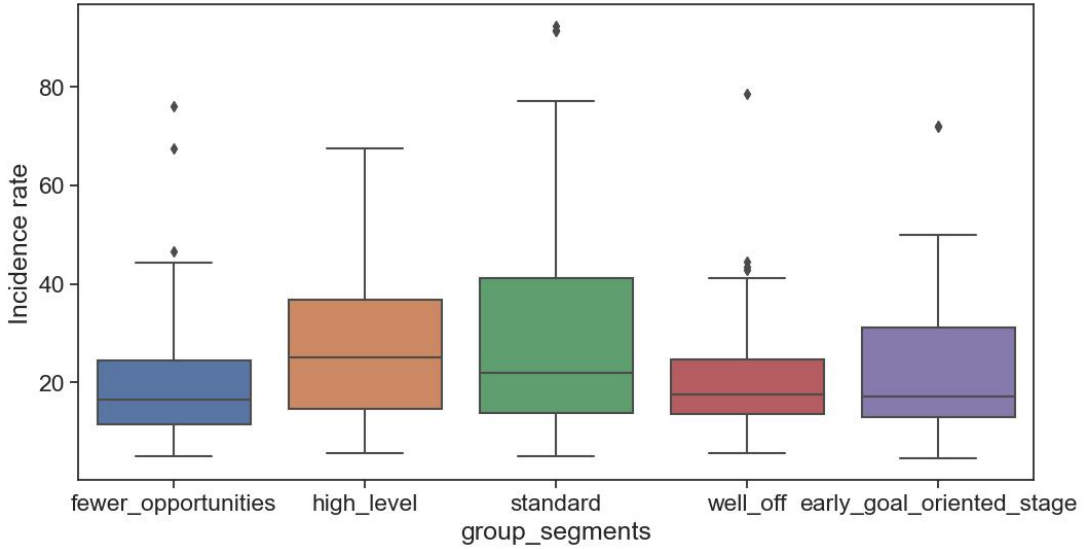

Exploratory Data Analysis

Segments_Brand

- 預設:Brand_1~_5，1的價格是最低，而5是最高
- 依照segments來看可以理解個別所偏好的品牌價格，右圖可以看到Career-Focused和Well-Off分別對4及5的品牌有所偏好，比較特別的是fewer opportunity的品牌偏好竟然不是價格最低的，所以在定價策略上面最低價絕對不是最好的選擇。

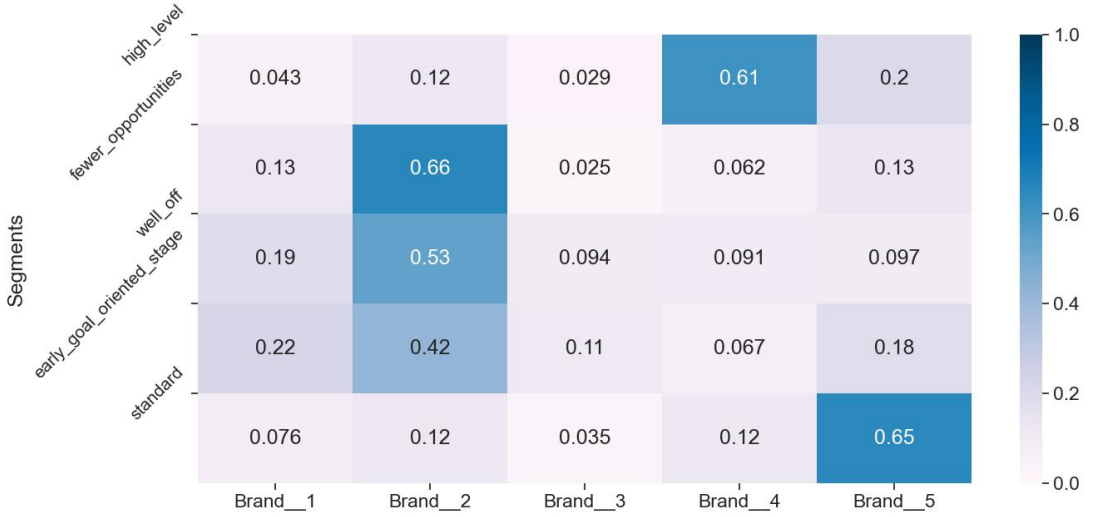


```
#把brand攤開成欄的方式去檢視
df_purchase_incidence = df_purchase_predictors[df_purchase_predictors['Incidence'] == 1]
brand_dummies = pd.get_dummies(df_purchase_incidence['Brand'], prefix = 'Brand', prefix_sep = '_')
brand_dummies['Segment'], brand_dummies['ID'] = df_purchase_incidence['Segment'], df_purchase_incidence['ID']
#檢視Segments各Brand的平均購買比例
temp = brand_dummies.groupby(['ID'], as_index = True).mean()
mean_brand_choice = temp.groupby(['Segment'], as_index = True).mean()

sns.heatmap(mean_brand_choice,
            vmin = 0,
            vmax = 1,
            cmap = 'PuBu',
            annot = True)
plt.yticks([0, 1, 2, 3], ['Standard', 'Career-Focused', 'Fewer-Opportunities', 'Well-Off'], rotation = 45, fontsize = 9)
plt.title('Average Brand Choice by Segment')
plt.show()
```

Price elasticity formula

公式為數量的變動對於價格的變動比例，一般如果|E|<1，都歸類為inelastic，簡單來說當財貨價格產生變動時，對需求的影響較小。

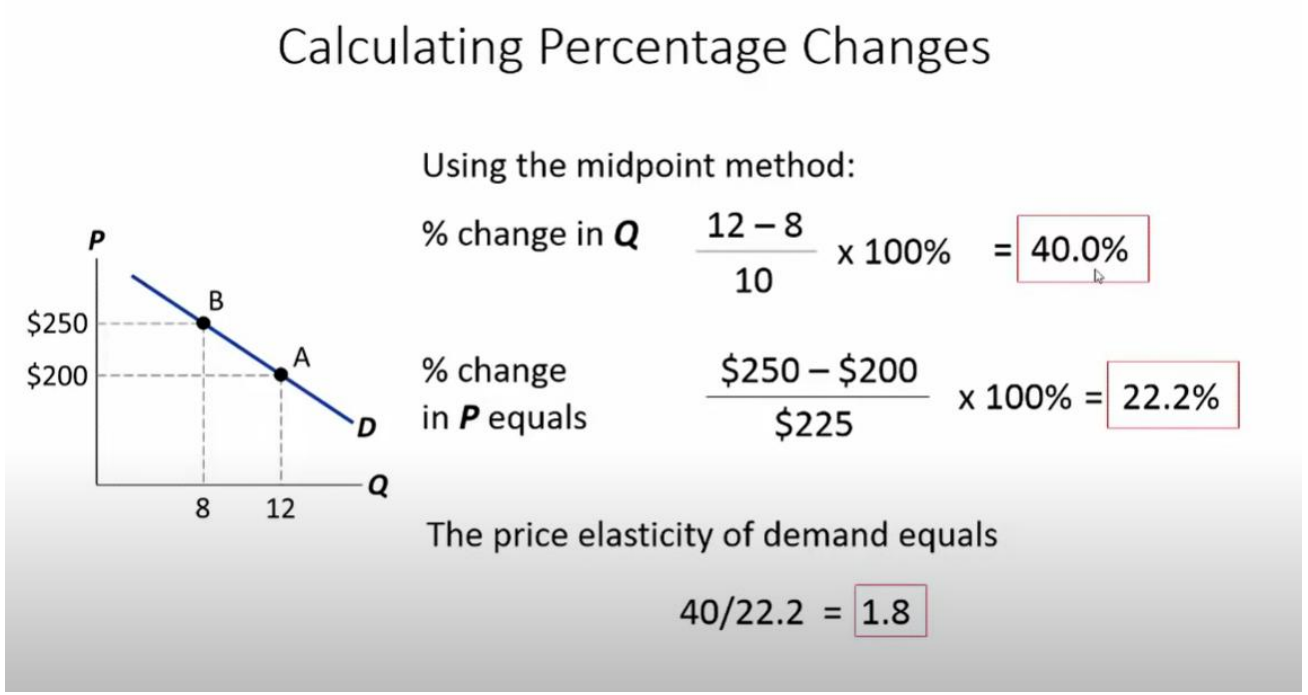

經過數學公式轉換求得下面公式，得以利用Python計算:

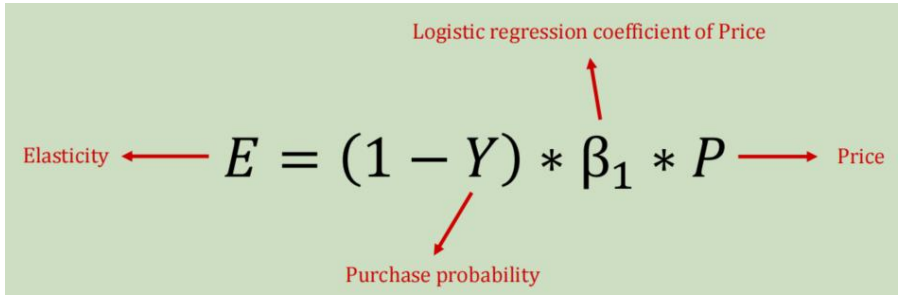

右圖片來源 : https://www.youtube.com/watch?v=5UKw4blQdsc

Price Elasticity of Purchase Probability

Coeficient

利用LogisticRegression先求出相關係數(Coefficient)，該資料裡的所有價格做加總再平均後得出X，拿平均價格(X)和發生購買事件(Y)做訓練求得相關係數

```
#使用原資料df_purchase_predictors改名為df_pa
df_pa = df_purchase_predictors
#要預測purchase probability，故把Incidence設為Y，把所有價格平均設為X
Y = df_pa['Incidence']
df_purchase_predictors
X = pd.DataFrame()
X['Mean_Price'] = (df_pa['Price_1'] +
                   df_pa['Price_2'] +
                   df_pa['Price_3'] +
                   df_pa['Price_4'] +
                   df_pa['Price_5'] ) / 5
#使用Logistic Regression模型，fit模型(X,Y)
model_purchase = LogisticRegression(solver = 'sag')
model_purchase.fit(X, Y)
model_purchase.coef_
```

```
array([[-2.34816446]])
```

Price Elasticity of Purchase Probability

Average Price

```
price_range = np.arange(0.5, 3.5, 0.01)
#算出LogisticRegression的predict_proba算出Purchase Probability
df_price_range = pd.DataFrame(price_range)
Y_pr = model_purchase.predict_proba(df_price_range)
purchase_pr = Y_pr[:][:, 1]
#Elasticity 公式 E = (1-Y)*B*P
pe = model_purchase.coef_[:, 0] * price_range * (1 - purchase_pr)
#
plt.figure(figsize = (9, 6))
plt.plot(price_range, pe, color = 'grey')
plt.xlabel('Price')
plt.ylabel('Elasticity')
plt.title('Price Elasticity of Purchase Probability')
```

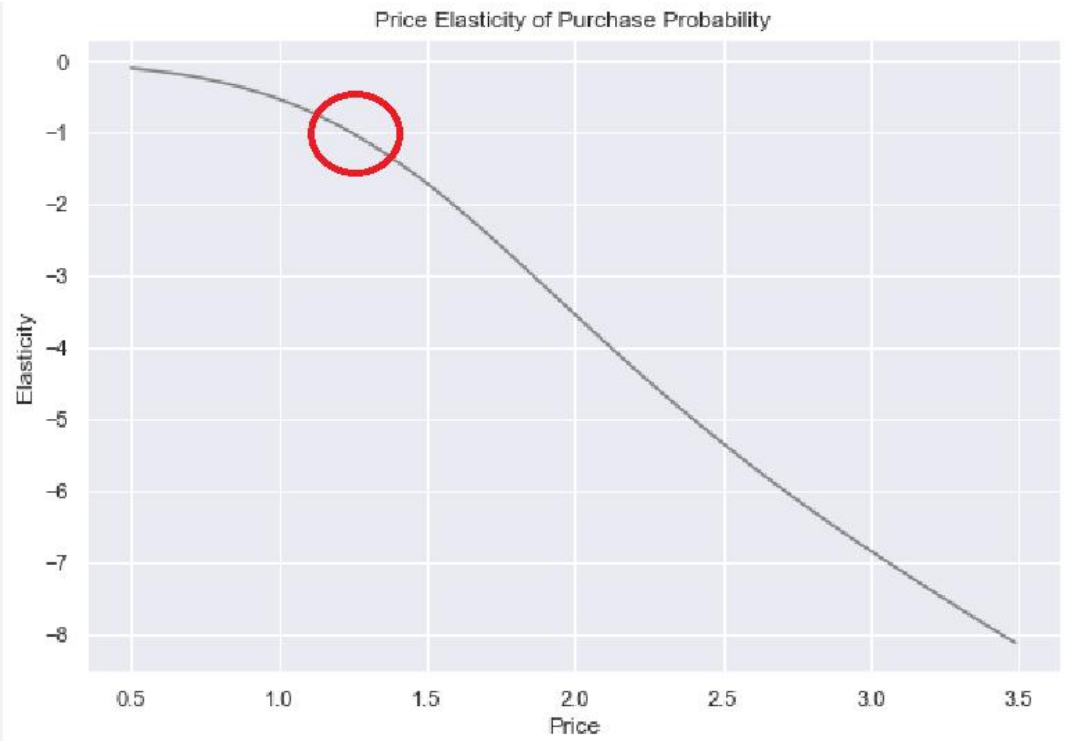

上圖可以看到，價格彈性跟價格是負相關的。在差不多價格1.3元之後，消費者對於商品價格將會比較強烈的回應。

Purchase Probability by Segments

利用價格彈性公式可以看到不同的族群對於價格有不同的反應，其中紅色線是最明顯的，在約1.5元之後就呈現急速下降，其次是藍色線，也就是我們的well_off族群，可以想像，因為先前已經看到這兩個族群對該品牌並沒有特別偏好，故價格對他們的影響也會比其他三個族群高。

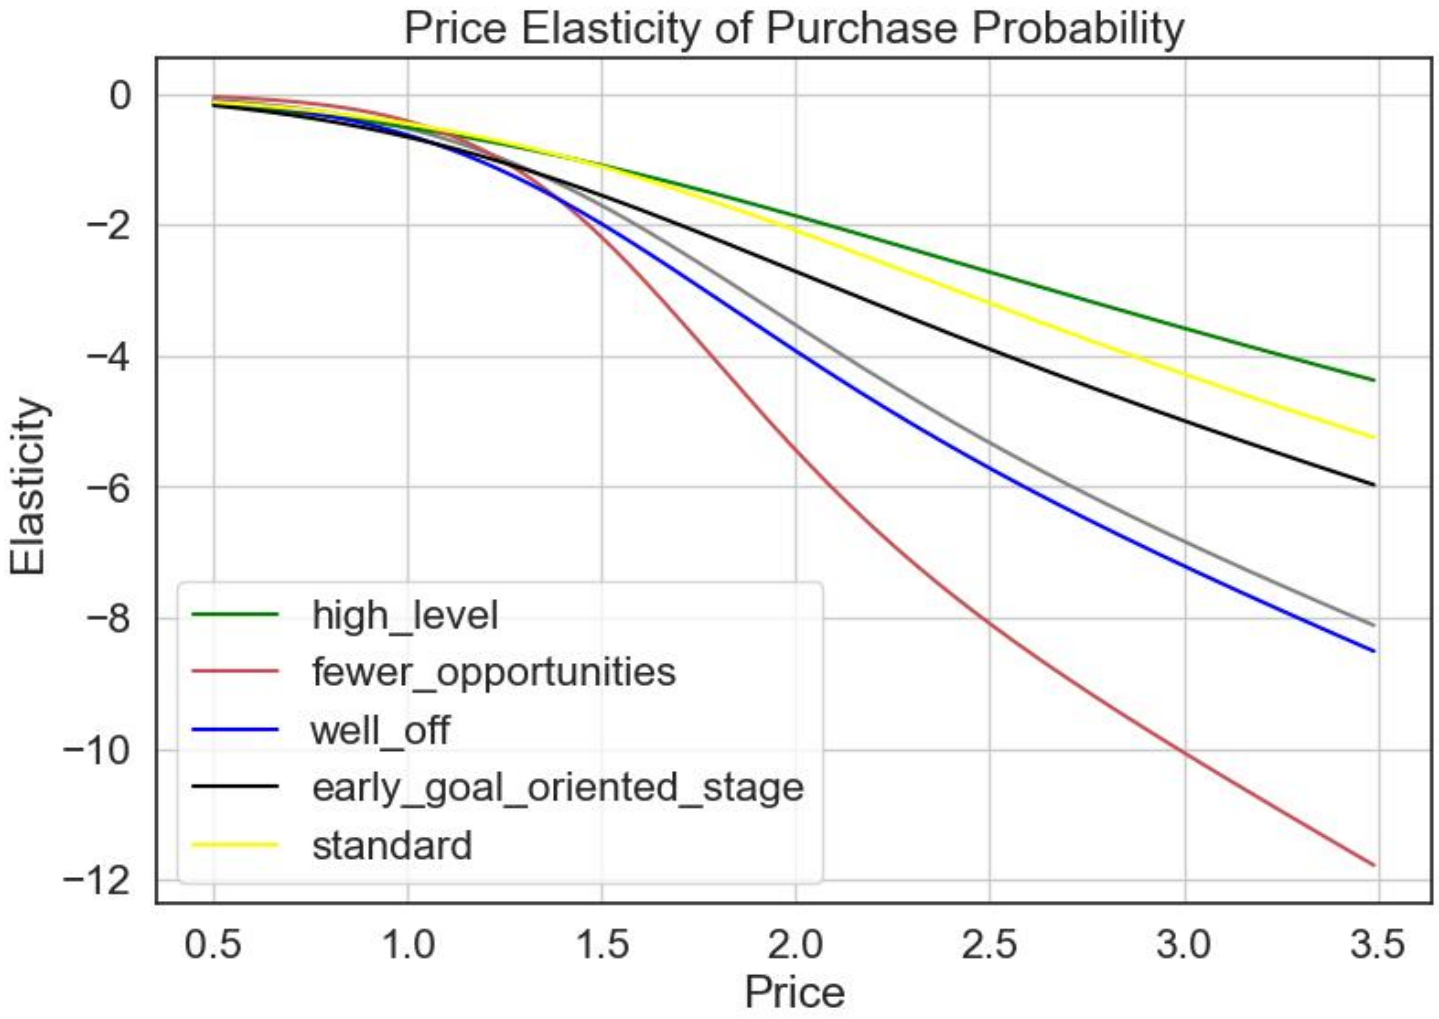

PySpark & Scikit-learn

利用隨機樹演算法進行網格搜索以及交叉驗證，針對消費者購買的品牌做預測，分數(accuracy)落在0.65附近。

訓練參數包含：

1. 該消費者特徵分群
2. 各牌子的價格
3. 各牌子是否有促銷
4. 第幾天到訪

共12種

總結:

- 這次的分析整理得到三個結論:
  1. 運用三種模型針對顧客特徵有效進行分類，藉此可以增加預測準確度。
  2. 將分類好的特徵結合價格彈性公式可以知道各族群對於價格的反應程度，對於賣家，可以藉此資訊調整售價，對於商場，可以進行商品曾列位置更動，比方說：依造上述的分析結果，可將第4及第5的牌子陳列在醒目的位置。
  3. 使用PySpark以及sickit-learn對該資料預測分數並不高，有可能是給予的特徵不足以判斷或是資料量太少。
- 經過這次的分析，對於顧客的掌握度提高，更加瞭解目標客群，針對不同客群做出不同對策，對於公司未來產品發展會有明顯的幫助，至於預測結果可以蒐集更多特徵優化預測結果。